

W04A · 이웃을 고려한 CF와 사용자의 평가 경향

딥러닝응용I(추천시스템) · 동덕여자대학교 데이터사이언스전공 · 유원상 교수 · 2026-2

2026년 9월 22일 화요일 · 4주차 1차시 · 주교재 3.4-3.6 · 75분

오늘의 목표와 수업 흐름

기본 CF는 유사한 사용자의 평점을 가중평균했다. 오늘은 “누구의 평점을 얼마나 사용하고, 각자의 점수 습관을 어떻게 보정할까?”를 다룬다.

- 목표 영화를 평가한 사람 중 이웃을 선택한다.
- 검증 데이터로 이웃 수를 결정하고 테스트 데이터의 역할을 구분한다.
- 이웃의 평점편차를 집계한 뒤 대상 사용자의 평균으로 되돌린다.
- 기존 추천 앱에 이웃 수와 평균 보정 조절 기능을 추가한다.

흐름	시간	확인할 결과
기존 CF 복습	8분	관측 마스크와 영화별 평가자
3.4 이웃을 고려한 CF	15분	KNN-Thresholding과 실제 이웃
3.5 최적 이웃 크기	12분	검증/테스트 분리와 비교표
3.6 평가 경향 보정	15분	관측 평균·편차·평점 복원
실습과 누적 앱	20분	설정에 따라 달라지는 근거 표
점검 퀴즈	5분	핵심 구별 일곱 가지

[학생 Colab 실습](#) · [강의 PDF](#) · [점검 퀴즈 해설 PDF](#)

1. 출발점: 평점표와 영화별 근거

다음은 W03B에서 사용한 독자 합성 자료다. MovieLens의 실제 사용자나 일부 자료가 아니다. 대시는 미관측이다.

사용자	A	B	C	D	E	관측 평균
U1	5	3	1	—	—	3.0
U2	4	2	1	5	2	2.8
U3	1	3	5	1	5	3.0
U4	5	3	—	4	—	4.0
U5	—	—	—	2	4	3.0

사용자 u 가 영화 i 에 준 관측 평점을 r_{ui} , 사용자 유사도를 s_{uv} 라 하자. 미관측을 0으로 채운 벡터는 코사인 계산에만 쓴다. 평균과 관측 여부는 원본 표에서 계산한다.

$$s_{uv} = \frac{\mathbf{x}_u^T \mathbf{x}_v}{\|\mathbf{x}_u\|_2 \|\mathbf{x}_v\|_2}$$


이 수업은 지난 차시와 동일한 전체 영화 차원의 원평점 코사인을 유지한다. U1과 U4의 유사도는 약 0.812756, U2는 0.645423, U3은 0.411202, U5는 0이다. 유사도가 높아도 목표 영화를 평가하지 않았다면 그 영화의 예측에는 기여할 수 없다.

2. 3.4 · 이웃을 고려한 CF

2.1 KNN과 Thresholding

KNN(K-Nearest Neighbors)은 유사도가 높은 이웃을 최대 k 명 고른다. Thresholding은 유사도가 정한 임계값 τ 보다 큰 사람을 고른다. 여기서 KNN은 분류기의 다수결이 아니라 평점 예측에 사용할 사용자의 선택이다.

선택 방식	직접 정하는 값	결과로 달라지는 값
KNN	최대 이웃 수 k	마지막 이웃의 유사도
Thresholding	유사도 임계값 τ	선택된 이웃 수
함께 적용	임계값과 최대 수	두 조건을 만족하는 실제 이웃



그림은 목표 D의 평가자 중 양의 유사도인 U4·U2·U3만 보여 준다. $k = 2$ 면 U4와 U2, $\tau = 0.7$ 이면 U4만 남는다. 평가자 수가 부족하면 실제 이웃 수는 k 보다 작다. 우리 구현은 경계에서 엄격한 $\text{similarity} > \text{threshold}$ 를 사용한다.

2.2 먼저 평가자를 고르고, 그 안에서 이웃을 선택한다

1. 목표 영화 i 를 평가한 사용자를 남긴다.
2. 대상 사용자 자신과 0 이하 유사도를 제외한다. 임계값이 있으면 함께 적용한다.

3. 유사도 내림차순으로 정렬한다. 동점은 사용자 ID 오름차순으로 고정한다.
4. 최대 k 명을 고르고 같은 집합으로 분자와 분모를 계산한다.

영화 E에서는 가장 유사한 U4가 E를 평가하지 않았다. 따라서 $k = 1$ 이어도 U2를 골라야 한다. 전체 사용자 중 U4 한 명을 먼저 고른 뒤 E 미평가자를 지우면 유효한 U2를 놓친다.

선택된 집합을 $N_{u,i}^{(k,\tau)}$ 라 쓰면 기본 예측은 다음과 같다.

$$\hat{r}_{ui} = \frac{\sum_{v \in N_{u,i}^{(k,\tau)}} s_{uv} r_{vi}}{\sum_{v \in N_{u,i}^{(k,\tau)}} s_{uv}}$$

2.3 D의 평점을 직접 계산하기

U1-D의 $k = 2$ 이웃은 U4와 U2다. 반올림하기 전 유사도로 계산한 결과는 약 4.442623점이다.

$$\hat{r}_{1D} = \frac{0.812756 \times 4 + 0.645423 \times 5}{0.812756 + 0.645423} \approx 4.442623$$

이웃 수	D에 사용한 이웃	원평점 예측
1	U4	4.000000
2	U4, U2	4.442623
전체	U4, U2, U3	3.685360

k 와 추천 수 N 은 다르다. k 는 각 영화의 예측에 사용할 사람 수를 제한한다. 추천 수 N 은 예측을 마친 뒤 화면에 표시할 미평가 영화의 수를 제한한다.

3. 3.5 · 최적의 이웃 크기 결정


3.1 무조건 작은 값이나 큰 값이 답은 아니다

작은 k 는 매우 유사한 소수에게 집중하지만 한 사람의 우연한 평점에 민감해질 수 있다. 큰 k 는 근거를 늘리지만 상대적으로 덜 비슷한 사용자의 의견을 섞는다. 따라서 한쪽 방향의 변화가 항상 성능을 높인다고 보장할 수 없다. 교재의 약 30명이라는 결과는 해당 실험 조건의 관측값이며 보편적 상수가 아니다.

영화별로 평가자 수가 다르므로 설정 k 와 실제 사용 인원은 다르다. RMSE뿐 아니라 CF 근거가 있었던 비율 (coverage), 평균 실제 이웃 수도 함께 본다.

3.2 검증으로 선택하고 테스트로 평가한다

이 부분은 교재 내용을 실습에서 신뢰할 수 있게 평가하기 위한 보충 절차다. 같은 테스트 데이터의 점수를 보면서 계속 설정을 고르면 테스트 데이터가 선택 과정에 간접적으로 사용된다.



1. 관측을 train 60%, validation 20%, test 20%로 나눈다.
2. train만으로 평점 행렬, 유사도, 사용자 평균을 만든다.
3. 같은 validation에서 후보 k 와 평균 보정 여부를 비교한다.
4. 검증 RMSE가 가장 작은 설정을 고정한다.
5. train+validation 80%로 다시 학습한다. test는 선택된 설정만 한 번 평가한다.

$$\text{RMSE} = \sqrt{\frac{1}{|V|} \sum_{(u,i) \in V} (r_{ui} - \hat{r}_{ui})^2}$$


V 는 현재 평가에 쓰는 관측 쌍 집합이다. 같은 사용자나 영화가 여러 분할에 등장할 수 있지만 동일한 사용자-영화 관측 쌍이 겹쳐서는 안 된다. 이 실습은 기존 사용자의 가려진 평점 예측이며 미래 시점 평가나 새 사용자 평가는 아니다.

3.3 이번 수업에서 실제 측정한 결과

MovieLens 100K의 943명·1,682편·100,000평점을 사용했다. 바깥 분할 seed는 20260922, 내부 분할 seed는 20260923이다. 사용자 층화 분할을 사용했고 임계값은 0, 자기 자신은 제외했다. 두 방식 모두 같은 원평점 코사인을 사용한다. 점수는 최종 1-5 범위 제한 후 계산했다.

k	원평점 검증 RMSE	평균 보정 검증 RMSE	평균 실제 이웃 수
1	1.363573	1.226644	1.00
5	1.074973	1.000196	4.95
10	1.038166	0.969805	9.79
20	1.022414	0.956232	19.07
30	1.019916	0.954880	27.77
40	1.019763	0.955412	35.78
60	1.020737	0.957472	49.75
전체(0)	1.023732	0.961973	98.44

MovieLens 100K · 동일한 검증 20,000개 관측



이번 후보 중 검증 최저는 **k=30, 평균 보정**, 검증 RMSE **0.954880**였다. 이 설정을 고정해 80,000행으로 재학습한 뒤 20,000개 테스트 관측에서 한 번 측정한 RMSE는 **0.934536**다. 테스트 CF coverage는 99.80%이고 clip이 적용된 예측은 245개였다. 이 결과는 교재의 실험 결과와 별개다.

이 수치는 이 구현·분할·후보 설정에 한정된다. 점수가 낮다고 모든 사용자에게 더 좋은 추천 순서를 제공한다고 결론 내리지는 않는다. 원평점/보정 방식의 근거 부족 대체 규칙도 다르므로 차이를 오직 한 수식의 효과로만 해석하지 않는다.

4. 3.6 · 사용자의 평가 경향을 고려한 CF

4.1 같은 4점도 의미가 다를 수 있다

평소 4점을 주는 사람의 4점은 보통 수준이다. 평소 2.8점을 주는 사람의 5점은 평소보다 2.2점 높은 평가다. 점수 자체 대신 “그 사람의 평소 수준에서 얼마나 벗어났는가?”를 비교한다.

사용자 v 가 train에서 평가한 영화 집합을 I_v 라 하면 관측 평균과 편차는 다음과 같다.

$$\bar{r}_v = \frac{1}{|I_v|} \sum_{j \in I_v} r_{vj}, \quad d_{vi} = r_{vi} - \bar{r}_v$$

$R.mean(axis=1)$ 은 영화 열들을 가로질러 사용자별 평균을 계산한다. pandas는 기본적으로 NaN을 제외한다. $R.fillna(0).mean(axis=1)$ 은 미관측을 0점으로 취급하므로 여기서 사용하지 않는다.

4.2 이웃의 편차를 집계하고 내 평균을 더한다

$$\hat{r}_{ui} = \bar{r}_u + \frac{\sum_{v \in N_{u,i}^{(k,\tau)}} s_{uv} (r_{vi} - \bar{r}_v)}{\sum_{v \in N_{u,i}^{(k,\tau)}} s_{uv}}$$

수식의 역할을 세 단계로 읽는다.

1. **이웃 기준 제거:** 각 이웃의 평점에서 그 이웃의 관측 평균을 뺀다.
2. **편차 집계:** 같은 이웃 집합과 유사도 가중치로 편차를 평균한다.

3. **내 기준 복원**: 대상 사용자 u 의 관측 평균을 더한다.

여기서 코사인 유사도는 원평점 벡터로 계산한 값을 그대로 사용한다. 평균을 뺀 벡터의 코사인이나 Pearson 유사도로 바꾸는 것은 별도의 설계 변경이다.

4.3 같은 U1-D, 같은 두 이웃

이웃	D 평점	이웃 평균	D 편차	정규화 가중치
U4	4	4.0	0.0	0.557377
U2	5	2.8	2.2	0.442623

$$\hat{r}_{1D} = 3.0 + (0.557377 \times 0 + 0.442623 \times 2.2) \approx 3.973770$$

원평점 방식은 약 4.442623, 평균 보정은 약 3.973770이다. U4의 4점을 U1에게 그대로 옮기는 대신 U4 기준으로 보통이라는 정보(편차 0)를 사용한다. 원점수의 크기만 보고 "보정하면 항상 낮아진다"라고 일반화할 수는 없다.



4.4 경계 조건도 예측의 일부다

조건	이번 실습의 처리	표시되는 근거
유효 이웃이 1명	그 1명의 평점/편차 사용	cf, 실제 이웃 1
보정 모드, 알려진 사용자, 이웃 없음	train 사용자 평균	user-mean
그 외 이웃 없음, 알려진 영화	train 영화 평균	movie-mean
사용자·영화가 모두 미등록	train 전체 평균	global-mean
보정값이 범위 밖	clip 전 값을 보존하고 최종값을 1-5로 제한	raw_prediction, prediction

교재 예제의 최소 이웃 처리와 이번 구현은 다르다. 교재 코드는 이웃이 1명 이하인 경우 원평점 방식에서 3점, 보정 방식에서 사용자 평균으로 대체한다. 여기서는 양의 근거가 1명이라도 있으면 사용한다. 이 차이를 숨긴 채 교재와 같은 RMSE를 기대해서는 안 된다.

원평점 양의 가중평균은 관측 평점 범위 안에 있지만, 대상 평균을 더한 편차 예측은 범위를 벗어날 수 있다. 근거 표의 합은 **clip 전 값**과 비교해야 한다.

5. 실습 · 이웃 설정을 조절하는 추천 앱

5.1 첫 셀부터 실행하기

Colab CPU 런타임에서 학생 실습을 연다. 첫 셀은 고정 수업 버전 2026-fall-w04a와 Gradio를 설치한다. 런타임 재시작 안내가 나오면 재시작한 뒤 첫 셀부터 실행한다. 데이터는 공식 배포처에서 자동 준비하며 재실행은 캐시를 사용한다.

기본 모드는 `real`이다. 다운로드 실패를 합성 자료 성공으로 숨기지 않는다. 네트워크 사용이 불가능할 때만 `DATA_MODE="synthetic"`을 직접 선택한다. 이때 화면에 합성이라고 표시되고 위 MovieLens 측정값과 비교할 수 없다.

5.2 재사용 API 읽기

```
model = NeighborCF(k=20, centered=True, threshold=0.0)
model.fit(train)
details = model.predict_details(pairs)
evidence = model.explain(user_id=1, movie_id=4)
```

API	입력 → 출력	주의할 점
<code>NeighborCF(k,centered,threshold)</code>	설정 → 모델 객체	k=0은 전체 이웃
<code>fit(train)</code>	관측 표 → 학습된 자기 자신	평가 정답을 섞지 않음
<code>predict_details(pairs)</code>	ID 두 열 → 예측/실제 인원/근거 종류	rating 열은 읽지 않음
<code>explain(u,i)</code>	사용자·영화 ID → 전체 선택 이웃 표	보정 시 평균+기여도합 확인
<code>validation_sweep(train,val)</code>	분리된 두 관측 표 → 검증 비교표	test 입력 없음
<code>neighbor_view(...)</code>	모델과 화면 설정 → 요약/추천/근거	서버 없이 callback 확인 가능

모델 정의와 docstring · 앱과 callback 정의

5.3 앱의 입력과 출력 연결

사용자 ID, k, 평균 보정, 임계값, N → 버튼의 callback → 같은 학습 통계로 새 예측 → 추천 목록과 첫 추천의 전체 이웃 근거.

화면 조작은 재학습이나 테스트 데이터 선택이 아니다. 검증용 모델로 설정의 효과를 살펴보는 탐색이다. 기존 기본 CF와 네 방법 비교 탭도 함께 유지한다. Gradio 공유 링크는 런타임이 종료되면 작동하지 않으므로 수업의 영구 링크는 Colab 링크다.

5.4 실습에서 수행할 여섯 활동

- E1: 목표 영화 평가자 필터와 top-k 순서를 완성한다.
- E2: 유사도만 따로 정렬해서 생긴 평점 대응 오류를 고친다.
- E3: test 대신 validation에서 설정을 선택한다.
- E4: 행 평균·이웃 평균 제거·대상 평균 복원을 점검한다.
- E5: 원평점과 평균 보정 추천을 근거 표로 비교한다.
- E6: 화면 입력과 callback 인자의 순서를 연결한다.

활동의 빈칸은 독립 시연을 막지 않도록 구성했다. 먼저 예상과 근거를 적은 뒤 실행한다. 별도로 제출하는 채점 과제는 없다.

점검 퀴즈

1. 이웃 수 k 와 추천 수 N 은 각각 무엇을 제한하는가?
2. 목표 영화의 미평가자를 제거하는 일과 상위 k 명 선택 중 무엇을 먼저 해야 하는가?
3. KNN과 Thresholding은 이웃 수와 유사도 중 무엇을 직접 통제하는가?
4. 검증 RMSE가 최소인 k 를 찾을 때 테스트 데이터를 반복 사용하면 어떤 문제가 생기는가?
5. 사용자 평점을 구할 때 미관측 평점을 0으로 채운 표를 사용하면 안 되는 이유는 무엇인가?
6. 평점편차 기반 CF에서 이웃 평균을 빼고 마지막에 대상 사용자 평점을 더하는 이유는 무엇인가?
7. 평균 보정 후 예측이 5를 넘거나 유효 이웃이 없으면 어떻게 해석해야 하는가?

오늘 가져갈 세 문장

1. 이웃은 목표 영화별로 선택하며 k 는 최대 수다.
2. 이웃 크기는 검증으로 선택하고 테스트는 마지막 평가에 남긴다.
3. 사용자 평점편차를 모은 뒤 대상 사용자 평균으로 되돌린다.

참고자료와 출처 구분

- 주교재 3.4–3.6: 이웃 선택, 이웃 크기, 사용자 평가 경향 보정의 용어와 설명 흐름을 따른다. 그림3-2/3-3은 개념만 참고했으며 본문의 도식·합성 예·코드·측정 그래프는 수업용 독립 제작이다. 교재 스캔과 출판사 코드를 배포하지 않는다.
- [Surprise 공식 k-NN 문서](#): 원평점/사용자 평균 보정 수식 교차 확인. 이 실습은 Surprise 패키지 실행이 아닌 자체 구현이다.
- [scikit-learn 공식 교차검증 안내](#): 검증과 최종 테스트의 역할을 구분하는 보충 설명.
- [GroupLens MovieLens 100K](#): 실제 데이터의 공식 배포처. 원본을 이 저장소에 재배포하지 않는다.
- [W03B 계산 복습](#): 관측 마스크·코사인·가중평균의 연결.

외부 문서와 측정 조건 확인: 2026-09-22. 검증 데이터 분리, 명시적 대체/clip 정책, 앱의 근거 표시는 이해와 재현성을 위한 수업 보충이다.